

# 人工智能代数学基础大作业：线性代数在 概率统计中的运用

112401520 王郑涵 152401213 邱镇海

2026 年 1 月 10 日

# 目录

<b>1 引言</b>	<b>4</b>
1.1 选题 . . . . .	4
1.2 分工 . . . . .	4
<b>2 学习笔记</b>	<b>4</b>
2.1 均值, 方差和概率 . . . . .	4
2.1.1 基本定义 . . . . .	4
2.1.2 Monte Carlo Estimation Methods . . . . .	5
2.2 协方差矩阵 . . . . .	6
2.2.1 定义与性质 . . . . .	6
2.2.2 性质 . . . . .	6
2.3 加权最小二乘与卡尔曼滤波 . . . . .	6
2.3.1 加权最小二乘 . . . . .	6
2.3.2 卡尔曼滤波 . . . . .	7
<b>3 课后习题解答</b>	<b>8</b>
3.1 习题 1 . . . . .	8
3.2 习题 2 . . . . .	9
3.3 习题 3 . . . . .	10
3.4 习题 4 . . . . .	11
3.5 习题 5 . . . . .	12
3.6 习题 6 . . . . .	14
3.7 习题 7 . . . . .	15
3.8 习题 8 . . . . .	17
<b>4 编程实验</b>	<b>18</b>
4.1 实验: 加权最小二乘 . . . . .	18
4.1.1 实验目的 . . . . .	18

目录	3
4.1.2 理论模型	18
4.1.3 数据构造	19
4.1.4 实验步骤	20
4.1.5 可视化结果与解释	20
5 学习心得	25

# 1 引言

## 1.1 选题

本报告选取了 Introduction to Linear Algebra 中 Chapter 12 的内容，报告包括三个部分：

- 学习笔记
- 课后习题
- 学习心得

## 1.2 分工

- 王郑涵：主要负责了学习笔记书写和编程实验实现。
- 邱镇海：主要负责了课后习题解答书写和编程实验书写。

# 2 学习笔记

## 2.1 均值，方差和概率

### 2.1.1 基本定义

我们从基本的几个统计量出发。

- 样本均值：

对于样本  $x_1, \dots, x_N$ ，样本均值  $m = \frac{1}{N} \sum_{i=1}^N x_i$ 。

- 方差和样本方差：

方差描述了数据围绕均值的离散程度。样本方差描述了相对于样本均值的距离，方差描述了相对于期望的平均距离。

方差定义为  $\sigma^2 = \mathbb{E}((x - m)^2) = \sum_{i=1}^n p_i(x_i - m)^2$ 。

样本方差定义为  $S^2 = \frac{1}{N-1} \sum_{i=1}^N (x_i - m)^2$ 。 $S^2$  是  $\sigma^2$  的无偏估计。

- 协方差:  $\sigma_{12} = \sum_i \sum_j p_{ij}(x_i - m_1)(y_j - m_2)$ 。
- 相关系数:  $\rho = \frac{\sigma_{xy}}{\sigma_x \sigma_y}$ , 其中  $\sigma_{xy}$  为  $x, y$  的协方差,  $\sigma_x, \sigma_y$  分别为  $x, y$  的标准差。

对于概率密度函数, 我们能求出均值和方差:

$$m = \mathbb{E}[x] = \int xp(x)dx$$

$$\sigma^2 = \mathbb{E}[(x - m)^2] = \int (x - m)^2 p(x)dx$$

### 2.1.2 Monte Carlo Estimation Methods

科学计算必须处理数据中的误差。金融计算必须处理不确定的数值和不确定的预测。我们需要接受输入中的不确定性, 并估计输出中的方差。

通常我们并不知道概率分布  $p(x)$ , 我们能做的就是通过不同的输入  $b$  得到若干个输出  $x(b)$ , 然后通过样本均值来估计期望。这就是蒙特卡洛方法最简单的形式, 这样的误差大概是  $\frac{1}{\sqrt{N}}$  级别的, 由于每次得到输出的计算成本可能很大, 这样的效率是不够好的。

多层蒙特卡洛 (Multilevel Monte Carlo) 是更加优秀的方法, 我们找到另一个函数  $y(b)$  使得计算它的成本比  $x(b)$  小得多, 并且两者十分接近。那么我们便可以用  $N$  次关于  $y(b)$  的计算和  $N^* < N$  次关于  $x(b)$  的计算来估计  $\mathbb{E}[X]$ 。

$$\text{2-level Monte Carlo: } \mathbb{E}[x] \approx \frac{1}{N} \sum_{k=1}^N y(b_k) + \frac{1}{N^*} \sum_{k=1}^{N^*} [x(b_k) - y(b_k)]. \quad (1)$$

设  $y(b)$  计算成本为  $C$ ,  $x(b)$  计算成本为  $C^*$ , 在总成本固定的前提下, 我们可以最小化方差, 最佳比例为  $\frac{N^*}{N} = \sqrt{\frac{C}{C^*} \frac{\sigma^*}{\sigma}}$ 。

## 2.2 协方差矩阵

### 2.2.1 定义与性质

定义：已知试验的结果取值向量  $\mathbf{X}$  以及均值  $\bar{\mathbf{X}} = \mathbb{E}[\mathbf{X}]$ ，协方差矩阵为

$$\mathbf{V} = \mathbb{E}[(\mathbf{X} - \bar{\mathbf{X}})(\mathbf{X} - \bar{\mathbf{X}})^T] \quad (2)$$

### 2.2.2 性质

- 协方差矩阵至少是半正定的（当变量相互独立时，它是正定的，且是对角矩阵）。协方差矩阵同时也是对称矩阵。
- 由于协方差矩阵  $\mathbf{V}$  是对称矩阵，我们可以把它分解成  $\mathbf{V} = \mathbf{Q}\Lambda\mathbf{Q}^T$ 。这样我们得到了若干个特征值  $\lambda_i \geq 0$  和若干个正交的单位特征向量  $q_i$ ，原来的若干个试验相当于分解得到的若干个独立试验的线性组合。
- 对原向量  $\mathbf{X}$  做线性变换得到  $\mathbf{Z} = \mathbf{AX}$ ，那么  $\mathbf{Z}$  的协方差矩阵为

$$\mathbf{V}_Z = \mathbf{A}\mathbf{V}_X\mathbf{A}^T \quad (3)$$

## 2.3 加权最小二乘与卡尔曼滤波

### 2.3.1 加权最小二乘

我们知道对于一个无解的线性方程  $\mathbf{Ax} = \mathbf{b}$ ，我们选择  $\hat{\mathbf{x}}$  来最小化误差  $\|\mathbf{b} - \mathbf{Ax}\|^2$ ，有方程  $\mathbf{A}^T\mathbf{A}\hat{\mathbf{x}} = \mathbf{A}^T\mathbf{b}$ 。

当  $\mathbf{b}$  的测量误差是相互独立的随机变量，均值为 0，方差为 1 且服从正态分布，那么最小二乘法是合适的。当其不独立或方差不同时，需要使用加权最小二乘法。

误差为

$$\mathbf{E} = (\mathbf{b} - \mathbf{Ax})^T \mathbf{V}^{-1} (\mathbf{b} - \mathbf{Ax})$$

方程变为

$$\mathbf{A}^T \mathbf{V}^{-1} \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^T \mathbf{V}^{-1} \mathbf{b} \quad (4)$$

为了衡量整个试验的可靠性，我们同样考虑  $\hat{\mathbf{x}}$  的均方误差，并将其与输入的协方差矩阵建立联系。我们有矩阵  $\mathbf{W}$ :

$$\mathbf{W} = \mathbb{E}[(\hat{\mathbf{x}} - \mathbf{x})(\hat{\mathbf{x}} - \mathbf{x})^T] = (\mathbf{A}^T \mathbf{V}^{-1} \mathbf{A})^{-1} \quad (5)$$

假设  $\mathbf{b}$  的协方差矩阵为  $\mathbf{V}$ ,  $\hat{\mathbf{x}} = \mathbf{L}\mathbf{b}$ 。由 (3) 可知,  $\hat{\mathbf{x}}$  的协方差矩阵为  $\mathbf{L}\mathbf{V}\mathbf{L}^T$ 。由 (4) 可知

$$\mathbf{L}\mathbf{V}\mathbf{L}^T = (\mathbf{A}^T \mathbf{V}^{-1} \mathbf{A})^{-1} \mathbf{A}^T \mathbf{V}^{-1} \mathbf{V} \mathbf{V}^{-1} \mathbf{A} (\mathbf{A}^T \mathbf{V}^{-1} \mathbf{A})^{-1} = (\mathbf{A}^T \mathbf{V}^{-1} \mathbf{A})^{-1}$$

### 2.3.2 卡尔曼滤波

考虑一个动态问题：每次新增一个观测方程，如何根据之前的观测方程，状态转移方程和最优估计  $\hat{x}_{k-1}$  来更新最优估计  $\hat{x}_k$ 。

$$A_0 x_0 = b_0 \quad x_1 = F_0 x_0 \quad A_1 x_1 = b_1 \quad x_2 = F_1 x_1 \quad A_2 x_2 = b_2$$

$$x_{\text{new}} = F_{\text{old}} x_{\text{old}}$$

考虑简化的问题：不考虑矩阵  $F$ 。我们初始有  $A_0 x_0 = b_0$ ，有加权最小二乘方程

$$A_0^T V_0^{-1} A_0 \hat{x}_0 = A_0^T V_0^{-1} b_0 \quad (6)$$

现在新增一个方程

$$\begin{bmatrix} A_0 \\ A_1 \end{bmatrix} \hat{x}_1 = \begin{bmatrix} b_0 \\ b_1 \end{bmatrix}$$

有加权方程

$$\begin{bmatrix} A_0^T & A_1^T \end{bmatrix} \begin{bmatrix} V_0^{-1} & \\ & V_1^{-1} \end{bmatrix} \begin{bmatrix} A_0 \\ A_1 \end{bmatrix} \hat{x}_1 = \begin{bmatrix} A_0^T & A_1^T \end{bmatrix} \begin{bmatrix} V_0^{-1} & \\ & V_1^{-1} \end{bmatrix} \begin{bmatrix} b_0 \\ b_1 \end{bmatrix}. \quad (7)$$

有卡尔曼更新方程

$$\hat{x}_1 = \hat{x}_0 + K_1(b_1 - A_1 \hat{x}_0) \quad (8)$$

其中  $K_1$  是卡尔曼增益矩阵， $K_1$  又可以从方差-协方差矩阵  $W_1$  的逆得到：

$$W_1^{-1} = W_0^{-1} + A_1^T V_1^{-1} A_1 \quad (9)$$

$$K_1 = W_1 A_1^T V_1^{-1} \quad (10)$$

### 3 课后习题解答

#### 3.1 习题 1

已知样本方差  $S^2$  有如下两种等价形式 (其中  $m$  为样本均值):

$$S^2 = \frac{1}{N-1} \sum_{i=1}^N (x_i - m)^2 = \frac{1}{N-1} \left[ \left( \sum_{i=1}^N x_i^2 \right) - Nm^2 \right].$$

请验证: 期望方差 (加权方差)  $\sigma^2$  也有对应的等价恒等式。设

$$m = \sum_i p_i x_i,$$

证明

$$\sigma^2 = \sum_i p_i (x_i - m)^2 = \left( \sum_i p_i x_i^2 \right) - m^2.$$

解答:

从期望方差 (加权方差) 的定义出发:

$$\sigma^2 = \sum_i p_i (x_i - m)^2.$$

先展开平方项:

$$\begin{aligned} \sigma^2 &= \sum_i p_i (x_i^2 - 2x_i m + m^2) \\ &= \sum_i p_i x_i^2 - 2m \sum_i p_i x_i + m^2 \sum_i p_i. \end{aligned}$$

注意到给定条件

$$\sum_i p_i x_i = m \quad \text{且} \quad \sum_i p_i = 1,$$

代入可得

$$\begin{aligned}\sigma^2 &= \sum_i p_i x_i^2 - 2m(m) + m^2(1) \\ &= \sum_i p_i x_i^2 - 2m^2 + m^2 \\ &= \sum_i p_i x_i^2 - m^2.\end{aligned}$$

因此恒等式成立：

$$\sigma^2 = \left( \sum_i p_i x_i^2 \right) - m^2.$$

## 3.2 习题 2

**题目：**

掷一枚公平硬币  $N$  次，得到  $i$  次正面朝上的概率为

$$p_i = \frac{b_i}{2^N}, \quad b_i = \binom{N}{i} = \frac{N!}{i!(N-i)!}.$$

由于

$$\sum_{i=0}^N b_i = (1+1)^N = 2^N,$$

所以

$$\sum_{i=0}^N p_i = 1.$$

并且注意到  $b_i = b_{N-i}$ 。

**问题：**证明该分布的均值

$$m = 0 \cdot p_0 + 1 \cdot p_1 + \cdots + N \cdot p_N = \sum_{i=0}^N i p_i$$

等于  $\frac{N}{2}$ 。

解答：

我们计算

$$m = \sum_{i=0}^N i p_i = \frac{1}{2^N} \sum_{i=0}^N i \binom{N}{i}.$$

利用组合恒等式

$$i \binom{N}{i} = N \binom{N-1}{i-1},$$

于是

$$\sum_{i=0}^N i \binom{N}{i} = \sum_{i=1}^N N \binom{N-1}{i-1} = N \sum_{j=0}^{N-1} \binom{N-1}{j} = N \cdot 2^{N-1},$$

其中令  $j = i - 1$ , 并用到了

$$\sum_{j=0}^{N-1} \binom{N-1}{j} = (1+1)^{N-1} = 2^{N-1}.$$

因此

$$m = \frac{1}{2^N} \cdot N \cdot 2^{N-1} = \frac{N}{2}.$$

所以均值确实为  $\frac{N}{2}$ 。

### 3.3 习题 3

题目：

对任意函数  $f(x)$ , 其期望为

$$\mathbb{E}[f] = \sum_i p_i f(x_i) \quad \text{或} \quad \mathbb{E}[f] = \int p(x) f(x) dx$$

(分别对应离散概率与连续概率)。设均值为  $\mathbb{E}[x] = m$ , 方差为

$$\mathbb{E}[(x - m)^2] = \sigma^2.$$

求  $\mathbb{E}[x^2]$ 。

**解答:**

由方差定义

$$\sigma^2 = \mathbb{E}[(x - m)^2] = \mathbb{E}[x^2 - 2mx + m^2] = \mathbb{E}[x^2] - 2m\mathbb{E}[x] + m^2.$$

又因为  $\mathbb{E}[x] = m$ , 代入得

$$\sigma^2 = \mathbb{E}[x^2] - 2m^2 + m^2 = \mathbb{E}[x^2] - m^2.$$

因此

$$\mathbb{E}[x^2] = \sigma^2 + m^2.$$

### 3.4 习题 4

**题目:**

对于  $M = 3$  个相互独立的实验, 其均值分别为  $m_1, m_2, m_3$ , 方差分别为  $\sigma_1^2, \sigma_2^2, \sigma_3^2$ 。求它们的协方差矩阵  $V$ 。

**解答:**

由于三个实验相互独立, 因此不同实验之间协方差为 0:

$$\text{Cov}(X_i, X_j) = 0, \quad i \neq j$$

每个实验的方差为:

$$\text{Var}(X_i) = \sigma_i^2$$

因此协方差矩阵为对角矩阵:

$$V = \begin{pmatrix} \sigma_1^2 & 0 & 0 \\ 0 & \sigma_2^2 & 0 \\ 0 & 0 & \sigma_3^2 \end{pmatrix}$$

### 3.5 习题 5

**题目:**

对同一个变量  $x$  进行两次测量, 得到两条观测方程

$$x = b_1, \quad x = b_2.$$

假设两次测量误差均值为零, 方差分别为  $\sigma_1^2$  与  $\sigma_2^2$ , 且两次误差相互独立。

因此误差协方差矩阵

$$V = \begin{pmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{pmatrix}.$$

将两条方程写成  $Ax = b$  的形式 (其中  $A$  是  $2 \times 1$  矩阵)。

参照教材 Example 1, 求基于  $b_1, b_2$  的最优估计  $\hat{x}$ , 以及估计误差的方差

$$\mathbb{E}[\hat{x}\hat{x}^T].$$

**解答:**

#### (1) 写成矩阵形式

两条观测方程为

$$x = b_1, \quad x = b_2.$$

写成  $Ax = b$  形式:

$$A = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad b = \begin{pmatrix} b_1 \\ b_2 \end{pmatrix}.$$

误差协方差矩阵为

$$V = \begin{pmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{pmatrix}, \quad V^{-1} = \begin{pmatrix} \frac{1}{\sigma_1^2} & 0 \\ 0 & \frac{1}{\sigma_2^2} \end{pmatrix}.$$

### (2) 最小二乘（加权）最优估计

加权最小二乘解为

$$\hat{x} = (A^T V^{-1} A)^{-1} A^T V^{-1} b.$$

先计算：

$$A^T V^{-1} A = \begin{pmatrix} 1 & 1 \end{pmatrix} \begin{pmatrix} \frac{1}{\sigma_1^2} & 0 \\ 0 & \frac{1}{\sigma_2^2} \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2}.$$

再计算：

$$A^T V^{-1} b = \begin{pmatrix} 1 & 1 \end{pmatrix} \begin{pmatrix} \frac{1}{\sigma_1^2} & 0 \\ 0 & \frac{1}{\sigma_2^2} \end{pmatrix} \begin{pmatrix} b_1 \\ b_2 \end{pmatrix} = \frac{b_1}{\sigma_1^2} + \frac{b_2}{\sigma_2^2}.$$

因此

$$\hat{x} = \frac{\frac{b_1}{\sigma_1^2} + \frac{b_2}{\sigma_2^2}}{\frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2}}.$$

### (3) 估计误差方差

加权最小二乘估计的协方差为

$$\text{Var}(\hat{x}) = (A^T V^{-1} A)^{-1} = \left( \frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2} \right)^{-1}.$$

因此题目所求为

$$\mathbb{E}[\hat{x} \hat{x}^T] = \left( \frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2} \right)^{-1}.$$

### 3.6 习题 6

题目：

若随机变量  $x$  与  $y$  相互独立，其边缘概率密度分别为  $p_1(x)$  与  $p_2(y)$ ，  
则联合概率密度

$$p(x, y) = p_1(x)p_2(y).$$

通过将二维积分（积分区间均为  $(-\infty, \infty)$ ）拆分为两个一维积分的乘积，证明：

$$\iint_{-\infty}^{\infty} p(x, y) dx dy = 1, \quad \iint_{-\infty}^{\infty} (x + y) p(x, y) dx dy = m_1 + m_2.$$

其中

$$m_1 = \int_{-\infty}^{\infty} x p_1(x) dx, \quad m_2 = \int_{-\infty}^{\infty} y p_2(y) dy.$$

解答：

(1) 证明归一化：由于  $p(x, y) = p_1(x)p_2(y)$ ，

$$\iint p(x, y) dx dy = \iint p_1(x)p_2(y) dx dy.$$

先对  $x$  积分、再对  $y$  积分（或反之），可将其分离为乘积：

$$\iint p_1(x)p_2(y) dx dy = \left( \int_{-\infty}^{\infty} p_1(x) dx \right) \left( \int_{-\infty}^{\infty} p_2(y) dy \right).$$

而  $p_1, p_2$  都是概率密度，因此各自积分为 1：

$$\int_{-\infty}^{\infty} p_1(x) dx = 1, \quad \int_{-\infty}^{\infty} p_2(y) dy = 1.$$

故

$$\iint p(x, y) dx dy = 1 \cdot 1 = 1.$$

(2) 证明期望可加:

$$\iint (x + y)p(x, y) dx dy = \iint (x + y)p_1(x)p_2(y) dx dy.$$

利用线性拆分:

$$\iint (x + y)p_1(x)p_2(y) dx dy = \iint x p_1(x)p_2(y) dx dy + \iint y p_1(x)p_2(y) dx dy.$$

对第一项分离变量:

$$\iint x p_1(x)p_2(y) dx dy = \left( \int_{-\infty}^{\infty} x p_1(x) dx \right) \left( \int_{-\infty}^{\infty} p_2(y) dy \right) = m_1 \cdot 1 = m_1.$$

对第二项同理:

$$\iint y p_1(x)p_2(y) dx dy = \left( \int_{-\infty}^{\infty} p_1(x) dx \right) \left( \int_{-\infty}^{\infty} y p_2(y) dy \right) = 1 \cdot m_2 = m_2.$$

相加得

$$\iint (x + y)p(x, y) dx dy = m_1 + m_2.$$

证毕。

### 3.7 习题 7

题目:

继续第 6 题。设随机变量  $x, y$  相互独立, 因此联合概率密度

$$p(x, y) = p_1(x)p_2(y).$$

证明

$$\iint (x - m_1)^2 p(x, y) dx dy = \sigma_1^2, \quad \iint (x - m_1)(y - m_2) p(x, y) dx dy = 0.$$

因此  $2 \times 2$  的协方差矩阵  $V$  为对角矩阵, 其元素为 \_\_\_\_\_。

解答：

已知独立性给出  $p(x, y) = p_1(x)p_2(y)$ , 并记

$$m_1 = \mathbb{E}[X], \quad m_2 = \mathbb{E}[Y], \quad \sigma_1^2 = \text{Var}(X), \quad \sigma_2^2 = \text{Var}(Y).$$

(1) 证明  $\iint (x - m_1)^2 p(x, y) dx dy = \sigma_1^2$ :

$$\begin{aligned} \iint (x - m_1)^2 p(x, y) dx dy &= \iint (x - m_1)^2 p_1(x)p_2(y) dx dy \\ &= \int (x - m_1)^2 p_1(x) dx \int p_2(y) dy \\ &= \int (x - m_1)^2 p_1(x) dx \\ &= \text{Var}(X) = \sigma_1^2, \end{aligned}$$

其中用到  $\int p_2(y) dy = 1$ 。

(2) 证明  $\iint (x - m_1)(y - m_2) p(x, y) dx dy = 0$ :

$$\begin{aligned} \iint (x - m_1)(y - m_2) p(x, y) dx dy &= \iint (x - m_1)(y - m_2) p_1(x)p_2(y) dx dy \\ &= \left( \int (x - m_1) p_1(x) dx \right) \left( \int (y - m_2) p_2(y) dy \right) \\ &= (\mathbb{E}[X] - m_1)(\mathbb{E}[Y] - m_2) \\ &= (\mathbb{E}[X] - m_1)(\mathbb{E}[Y] - m_2) = 0. \end{aligned}$$

因此协方差矩阵

$$V = \begin{pmatrix} \text{Var}(X) & \text{Cov}(X, Y) \\ \text{Cov}(Y, X) & \text{Var}(Y) \end{pmatrix} = \begin{pmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{pmatrix}.$$

### 3.8 习题 8

题目：

设二维协方差矩阵

$$V = \begin{pmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{pmatrix},$$

证明其逆矩阵可写为

$$V^{-1} = \begin{pmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{pmatrix}^{-1} = \frac{1}{1 - \rho^2} \begin{pmatrix} \frac{1}{\sigma_1^2} & -\frac{\rho}{\sigma_1 \sigma_2} \\ -\frac{\rho}{\sigma_1 \sigma_2} & \frac{1}{\sigma_2^2} \end{pmatrix}, \quad \rho = \frac{\sigma_{12}}{\sigma_1 \sigma_2}.$$

并指出该形式会出现在二维高斯分布指数项

$$-(x - m)^\top V^{-1} (x - m)$$

中。

解答：

对任意  $2 \times 2$  矩阵

$$\begin{pmatrix} a & b \\ b & d \end{pmatrix},$$

若行列式  $ad - b^2 \neq 0$ , 则其逆为

$$\begin{pmatrix} a & b \\ b & d \end{pmatrix}^{-1} = \frac{1}{ad - b^2} \begin{pmatrix} d & -b \\ -b & a \end{pmatrix}.$$

令  $a = \sigma_1^2$ ,  $b = \sigma_{12}$ ,  $d = \sigma_2^2$ , 得到

$$V^{-1} = \frac{1}{\sigma_1^2 \sigma_2^2 - \sigma_{12}^2} \begin{pmatrix} \sigma_2^2 & -\sigma_{12} \\ -\sigma_{12} & \sigma_1^2 \end{pmatrix}.$$

又由相关系数定义  $\rho = \frac{\sigma_{12}}{\sigma_1 \sigma_2}$ , 可写

$$\sigma_{12} = \rho \sigma_1 \sigma_2, \quad \sigma_1^2 \sigma_2^2 - \sigma_{12}^2 = \sigma_1^2 \sigma_2^2 (1 - \rho^2).$$

代回并将分母因子拆开:

$$V^{-1} = \frac{1}{\sigma_1^2 \sigma_2^2 (1 - \rho^2)} \begin{pmatrix} \sigma_2^2 & -\rho \sigma_1 \sigma_2 \\ -\rho \sigma_1 \sigma_2 & \sigma_1^2 \end{pmatrix}.$$

将  $\sigma_1^2 \sigma_2^2$  分配进矩阵元素 (逐项相除):

$$V^{-1} = \frac{1}{1 - \rho^2} \begin{pmatrix} \frac{\sigma_2^2}{\sigma_1^2 \sigma_2^2} & -\frac{\rho \sigma_1 \sigma_2}{\sigma_1^2 \sigma_2^2} \\ -\frac{\rho \sigma_1 \sigma_2}{\sigma_1^2 \sigma_2^2} & \frac{\sigma_1^2}{\sigma_1^2 \sigma_2^2} \end{pmatrix} = \frac{1}{1 - \rho^2} \begin{pmatrix} \frac{1}{\sigma_1^2} & -\frac{\rho}{\sigma_1 \sigma_2} \\ -\frac{\rho}{\sigma_1 \sigma_2} & \frac{1}{\sigma_2^2} \end{pmatrix}.$$

证毕。

## 4 编程实验

### 4.1 实验: 加权最小二乘

#### 4.1.1 实验目的

本实验为加权最小二乘法和普通最小二乘法的对比:

1. 构造带异方差噪声的线性回归模型, 噪声方差随样本变化;
2. 对比普通最小二乘与加权最小二乘的参数估计差异;

#### 4.1.2 理论模型

假设带异方差噪声的一元线性模型:

$$y = ax + b + \varepsilon, \quad \mathbb{E}[\varepsilon_i] = 0, \quad \text{Var}(\varepsilon_i) = \sigma_i^2.$$

将其写成矩阵形式。令

$$\mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_N \end{bmatrix}, \quad A = \begin{bmatrix} x_1 & 1 \\ \vdots & \vdots \\ x_N & 1 \end{bmatrix}, \quad \boldsymbol{\beta} = \begin{bmatrix} a \\ b \end{bmatrix}, \quad \boldsymbol{\varepsilon} = \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_N \end{bmatrix},$$

则

$$\mathbf{y} = A\boldsymbol{\beta} + \boldsymbol{\varepsilon}.$$

**普通最小二乘:** 通过最小化平方残差  $\|\mathbf{y} - A\boldsymbol{\beta}\|_2^2$  得到解

$$\hat{\boldsymbol{\beta}}_1 = (A^T A)^{-1} A^T \mathbf{y}.$$

**加权最小二乘:** 若噪声协方差矩阵为

$$V = \text{diag}(\sigma_1^2, \dots, \sigma_N^2),$$

则权重矩阵取

$$W = V^{-1} = \text{diag}\left(\frac{1}{\sigma_1^2}, \dots, \frac{1}{\sigma_N^2}\right),$$

最小化加权残差二次型  $(\mathbf{y} - A\boldsymbol{\beta})^T W (\mathbf{y} - A\boldsymbol{\beta})$ , 其解为

$$\hat{\boldsymbol{\beta}}_2 = (A^T W A)^{-1} A^T W \mathbf{y}.$$

#### 4.1.3 数据构造

1. 生成自变量  $x_i$ : 在区间  $[x_{\min}, x_{\max}]$  内均匀采样;
2. 设定真实参数  $a, b$ , 构造真实直线  $y_i^* = ax_i + b$ ;
3. 令噪声标准差随  $x$  变化:

$$\sigma(x) = \sigma_0(1 + k|x|),$$

从而  $\sigma_i = \sigma(x_i)$ ;

4. 对每个样本生成噪声  $\varepsilon_i \sim \mathcal{N}(0, \sigma_i^2)$ , 并得到观测值

$$y_i = y_i^* + \varepsilon_i = ax_i + b + \varepsilon_i.$$

5. 参数:

- $N = 80, a = 2.0, b = -1.0$ ;
- $x_{\min} = -3.0, x_{\max} = 3.0$ ;
- $\sigma_0 = 0.06, k = 20$ 。

#### 4.1.4 实验步骤

1. 生成带异方差噪声的数据集  $\{(x_i, y_i, \sigma_i)\}_{i=1}^N$ ;

2. 分别用两种方法估计参数, 得到

$$\hat{\beta}_1 = \begin{bmatrix} \hat{a}_1 \\ \hat{b}_1 \end{bmatrix}, \quad \hat{\beta}_2 = \begin{bmatrix} \hat{a}_2 \\ \hat{b}_2 \end{bmatrix};$$

3. 计算并对比参数误差:

$$|\hat{a}_1 - a|, |\hat{b}_1 - b|, \quad |\hat{a}_2 - a|, |\hat{b}_2 - b|;$$

4. 计算预测误差 (相对于无噪声真值直线  $y^* = ax + b$ ) 的均方误差:

$$\text{MSE}(\hat{\beta}) = \frac{1}{N} \sum_{i=1}^N (\hat{a}x_i + \hat{b} - (ax_i + b))^2. \quad (11)$$

#### 4.1.5 可视化结果与解释

图 1 为异方差数据散点图。可以观察到, 当  $|x|$  较大时, 样本点围绕真实直线的离散程度明显增大; 而在  $|x|$  较小的区域, 数据点更加集中, 对应较小的噪声方差。

图 2 展示了权重  $w_i = 1/\sigma_i^2$  随  $x_i$  的变化关系。可以看到, 在噪声方差较小的区域, 权重更大; 在噪声方差较大的区域, 权重显著减小。这表明加权最小二乘会在拟合过程中更信任噪声较小的样本点, 从而降低高噪声样本对参数估计的干扰。

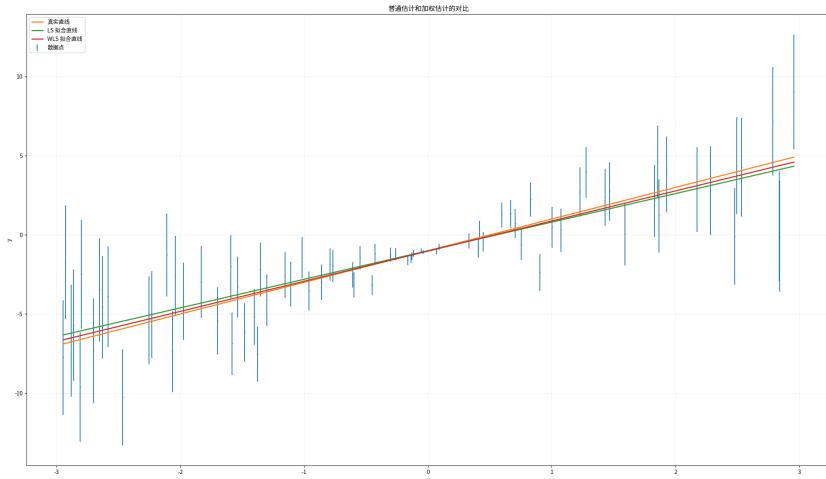


图 1: 数据分布

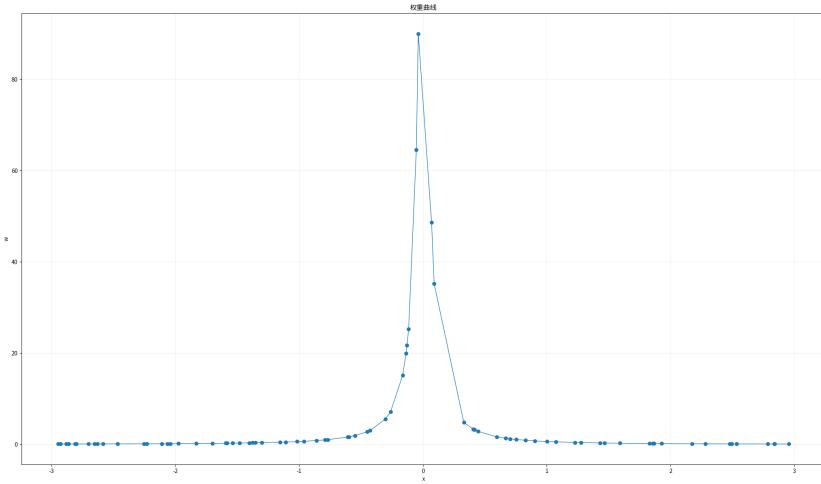


图 2: 权重曲线

**代码实现** 实验中数据生成与可视化的完整实现见 Listing 1。

Listing 1: main.py

```
1 import numpy as np
2 import matplotlib
3 import matplotlib.pyplot as plt
4
5 plt.rcParams['font.sans-serif'] = ['Noto Sans CJK JP']
6 plt.rcParams['axes.unicode_minus'] = False
7
8 def gen_data(N = 200, a = 2.0, b = -1.0, lf = -3.0, ri =
9     3.0, sigma_0 = 0.2, k = 0.25):
10    rng = np.random.default_rng(114514)
11    x = rng.uniform(lf, ri, size = N)
12    x = np.sort(x)
13    # print(x)
14    sigma = sigma_0 * (1.0 + k * abs(x))
15    eps = rng.normal(loc = 0.0, scale = sigma, size = N)
16    y = a * x + b + eps
17    return x, y, sigma
18
19 def least_squares(x, y):
20    A = np.column_stack([x, np.ones(len(x))])
21    # print(A)
22    sol = np.linalg.solve(A.T @ A, A.T @ y)
23    return sol
24
25 def weighted_least_squares(x, y, sigma):
26    A = np.column_stack([x, np.ones(len(x))])
27    inv_v = 1.0 / (sigma ** 2)
    W = np.diag(inv_v)
```

```
28     # print(W)
29     L = A.T @ W @ A
30     R = A.T @ W @ y
31     sol = np.linalg.solve(L, R)
32     return sol
33
34 def calc_MSE(x, xx, a, b):
35     y = a * x + b
36     y_hat = xx[0] * x + xx[1]
37     return np.mean((y_hat - y) ** 2)
38
39 if __name__ == "__main__":
40     a_true = 2.0; b_true = -1.0
41     # print(a_true, b_true)
42     x, y, sigma = gen_data()
43     sol1 = least_squares(x, y)
44     sol2 = weighted_least_squares(x, y, sigma)
45     # print(sol1)
46     # print(sol2)
47     print("真实参数 (a, b) = ", a_true, b_true)
48     print("普通最小二乘估计 (a_1, b_1) = ", sol1[0], sol1
49         [1])
50     print("加权最小二乘估计 (a_2, b_2) = ", sol2[0], sol2
51         [1])
52
53     print("\n a 误差: 普通:", abs(sol1[0] - a_true), " 加权: "
54         , abs(sol2[0] - a_true))
55     print("b 误差: 普通:", abs(sol1[1] - b_true), " 加权:",
56         abs(sol2[1] - b_true))
57
58     print("\n 普通 MSE = ", calc_MSE(x, sol1, a_true, b_true)
```

```
    ))
55 print("加权 MSE = ", calc_MSE(x, sol2, a_true, b_true))
56
57 # pic1
58 plt.figure()
59 plt.errorbar(x, y, yerr = sigma, fmt = 'o', markersize
60             = 3, capsizes = 2, label = "数据点")
61 xx = np.linspace(x.min(), x.max(), 200)
62 y_true = a_true * xx + b_true
63 y_1 = sol1[0] * xx + sol1[1]
64 y_2 = sol2[0] * xx + sol2[1]
65 plt.plot(xx, y_true, linewidth = 2, label = "真实直线")
66 plt.plot(xx, y_1, linewidth = 2, label = "LS 拟合直线")
67 plt.plot(xx, y_2, linewidth = 2, label = "WLS 拟合直线"
68             )
69 plt.title("普通估计和加权估计的对比")
70 plt.xlabel("x")
71 plt.ylabel("y")
72 plt.legend()
73 plt.grid(True, alpha = 0.2)
74 # plt.show()
75
76 # pic 2
77 plt.figure()
78 w = 1.0 / (sigma ** 2)
79 plt.plot(x, w, marker = 'o', linewidth = 1)
80 plt.title("权重曲线")
81 plt.xlabel("x")
82 plt.ylabel("w")
83 plt.grid(True, alpha = 0.2)
84 plt.show()
```

## 5 学习心得

本次学习感受最深的是协方差矩阵的分解，它把概率统计中的“独立”和线性代数中的正交对角化关联起来，是个非常有用的方法。

其次蒙特卡洛方法让我初步认识到了在科学计算中，可以从计算结构上改进，用便宜的近似模型提供主要贡献，再用少量昂贵模型修正偏差。

最后就是加权最小二乘法，让我学到了通过噪声方差的大小来加权估计，方差越小的数据越可靠，权重应该越大，这样可以得到更好的估计。